

研究生课程《地面无人平台自主控制》

激光雷达数据语义分割实验

实验总结报告

姓 名：郁有进

学 号：23050052

日 期：2024 年 1 月 27 日

一、实验目的

1. 实验目标

(1) 利用 KITTI odometry sequence 07 数据，结合其中的语义标注，参考网上开源代码，设计训练激光雷达数据语义分割网络以及场景补全网络。




图 1-1 激光雷达数据语义分割及补全示意图

(2) 通过本次实验了解激光雷达点云数据常用的语义分割分割及场景补全方法，详细了解所使用到的网络结构。

(3) 使用 Semantic-kitti、Semantic-POSS 等数据集进行实验，熟悉并掌握激光雷达数据的处理方法，并详细分析实验结果。

2. 实验环境

(1) Ubuntu 版本 linux 操作系统，本次实验使用 ubuntu20.04.06。

(2) ROS 版本 noetic。

(3) 编程语言 python。

(4) 编程集成开发环境：Qt5.14/VScode

二、实验方案、原理及方法

1. 总体实验方案

理解三维环境是人类的一项很自然的能力，可以利用先验知识去估计出几何和语义信息，即使是在大规模遮挡区域中，但是这对计算机来说是很困难的一件事情。事实上，3D 场景理解是许多应用程序的一个关键特性，如机器人导航或增强现实，其中几何和语义理解是与真实世界进行交互的关键。尽管如此，由于传感器有限的视野、稀疏传感和测量噪声等因素，只能提供世

界的部分观测，如图 2-1 所示。无人平台环境感知任务主要包括三大类：对场景中道路、地形、树木等静态物体的语义理解；对行人、车辆等动态物体的检测跟踪；对自身运动的估计以及周围环境的三维重建。




图 2-2 视觉传感器的感知能力

物体检测的只是针对动态物体的检测与追踪，输出是场景中感兴趣物体的位置，大小，类别，速度等信息。相对于点云数据来说，这些输出结果是非常稀疏的，只描述了场景内的一部分信息。除了车辆、行人的动态目标外，还有很多重要的信息是以非物体的形式存在的，比如说道路，建筑物，树木等等。如果没有这些信息，车辆就无法识别可以行驶的区域，也无法规避所有的障碍物，自动驾驶的功能也就会受到很多限制。语义分割的任务是给场景中的每个位置（图像中的每个像素，或者点云中的每个点）指定一个类别标签，比如车辆，行人，道路，建筑物等。语义分割和物体检测这两个任务有着很多的相似之处，其关键之处都在于如何有效的从原始点云数据中提取场景中的有用信息，以此对不同位置的语义信息进行解析。

虽然语义分割可以给每个点都赋予类别属性，但是由于激光雷达点云的稀疏性，场景中许多位置仍然是空白区域，这是不利于环境理解的。场景语义补全(SSC)旨在联合估计一个场景的完整几何形状和语义信息，如图 2-2 所示。




图 2-2 稀疏点云与补全场景

补全算法最初使用插值或者能量最小化技术来补全小规模或缺失区域。几何补全工作首先是致力于物体形状的补全，它可以推断出无遮挡的物体表示。比如，一些趋势利用了对称性。另一种常见的方法是依赖于先验 prior3D

模型来最佳地拟合稀疏输入数据。随着三维深度学习的最新进展，其中整个场景的语义和几何信息被联合推断，展现出较好地效果。SSC 包括场景表示、特征描述、稀疏到致密化过程以及结果评估与可视化等内容，其中从稀疏点云到致密化栅格地图是 SSC 任务的关键。目前主要的方法包括：

- 多尺度聚合(从多个尺度捕获局部几何细节和全局信息，能够消除场景中存在的相似对象之间的歧义)、
- 边缘信息利用(同一体素内相似，但场景表面、边缘和顶点处的体素由于其周围环境的方差较高而提供了丰富的几何信息)、
- 多模态融合(采用 2D 和 3D 模态的融合，可以实现更丰富的特征信息)。

文献^[1]中采用贝叶斯核函数的平滑方法来补全场景。在得到的语义分割结果基础上，通过贝叶斯判别方法将网络的 Softmax 输出与地图语义单元建立联系，然后给定核函数，定义平滑函数拟合空白区域。

2. 实验基本原理

2.1 分割算法

本实验中首先采用几种分割算法对 Semantic-Kitti 数据集进行分割实验，这里简要介绍采用的几种分割算法。

(1)RangeNet++

该算法将激光点云通过球面投影转换为距离图像 (Range Images)，然后在距离图像上用二维卷积神经网络提取特征进行语义分割。为了获得精确的分割效果，作者还提出了一种新的后处理算法用于处理由于投影变换带来的离散化误差或者卷积神经网络模糊的输出结果。RangeNet++提出的点云语义分割方法分为如下 4 个步骤：

点云投影

为了得到全部激光点云精确的语义分割结果，RangeNet++的第一步是通过球面坐标将每个三维空间的点转换到由距离图像表示的二维空间。

$$(u, v) = \left(\frac{1}{2} [1 - \arctan(y, x) / \pi] w, [1 - (\arcsin(z/r) + f_{up}) / f] h \right)$$

根据上面的公式，我们就可以把一帧点云转换为 $5 \times h \times w$ 的张量，其中的 5 个通道分别对应点云的 range、x、y、z、intensity 这 5 个属性。

全卷积语义分割

通过上一步将点云转换为距离图像后，得到的张量被送入一个

encoder-decoder 结构的全卷积语义分割网络 RangeNet53 中进行处理。在前面的 encoder 网络中，会对输入特征图做逐级下采样，最大的下采样倍数为 32 倍。encoder 操作做完后紧接着是一个 decoder 的网络，用于对特征图做上采样以恢复到原始输入图像的大小。每级上采样操作做完后还会将前面 encoder 网络中对应尺寸的输入结果进行相加，进行多尺度信息聚合。encoder 网络是由 Darknet53 修改而来，网络的输入由原来的 3 通道图像变为 5 通道的图像。




图 2-3 RangeNet++网络结构示意图

从距离图像中重建点云

为了从语义图像中推断出所有原始点云的语义信息，RangeNet++采用的方法是在第一步的时候为每个点保存一个该点在距离图像中的坐标索引 (u,v) ，通过这个坐标索引就可以从语义图像中查找到点云中每个点对应的语义标签。

高效的点云后处理

encoder-decoder 结构的全卷积语义分割网络会导致模糊不清的语义分割结果，为了解决这个问题，RangeNet++使用 kNN 搜索算法为语义点云中的每个点找到最接近的 k 个点的共识投票，减少从二维图像空间重投影到三维空间引起的“阴影”。

(2)PolarNet

RangeNet++将点云转换为 2D 图像后输入网络，而 PolarNet 使用 PointNet 提取 Voxel 内特征并转化为极坐标系下 BEV 图。这是因为根据激光雷达的发射原理，激光在近处密集远处稀疏，假如使用笛卡尔坐标系下的分割，会导致近处的 voxel 内点密集远处的 voxel 内点稀疏，而使用极坐标的情况下则没有这一问题。

针对极化 BEV 图，作者提出了环形卷积的概念，通过在 2D 网络中将常规卷积替换为环形卷积，该网络将能够端到端处理极坐标网格，而不会忽略其连通性。




图 2-4 环形卷积概念

最后使用 U-Net 作为基本的框架进行分割任务，U-Net 同样使用 Encoder-Decoder 结构，将不同尺度下的特征聚合。

2.2 补全模型

本实验中采用的是 JS3C-Net，JS3C-Net 是一个稀疏的 LiDAR 点云语义分割框架，将 SSC 作为辅助任务。它包括点体素交互（PVI）模块，以增强这种多任务学习并促进两个任务之间的知识转移。

对于语义分割，它使用 3D 稀疏卷积 U-Net。级联 SSC 模块预测粗略的完成结果，该结果在 PVI 模块中进行了细化。为了避免在解码器中应用密集卷积，S3CNet 提出了 BEV 和 3D 预测的动态体素后期融合，以进一步加密场景，然后应用空间传播网络来细化结果。




图 2-5 JS3C-Net 整体网络架构

如图 2-5 所示，分割网络直接使用点云的三维坐标作为输入，而忽略了其他特征，通过稀疏卷积的 U-Net 网络提取特征进行分割。

对于 SSC 模块，结构如图 2-5 所示。




图 2-5 SSC 模块

该网络以每点分类概率的不完整点云为输入，首先进行体素化以获得高

分辨率的 3D 体，并使用一个卷积层和一个池化层来降低分辨率和计算复杂度。然后，利用几个使用跳跃连接卷积的基本块来学习局部几何表示。然后，将不同尺度的特征进行拼接，聚合多个尺度的信息。最后通过上采样恢复原有分辨率，输出粗略预测的标签。

JS3C-Net 中通过 PVI 模块实现预测结果从粗向精的调整。将分割网络得到的点的特征与 SSC 粗略的预测结果作为输入，利用 KNN 找到原点云(输入网络前最初的点云)邻近的点，然后通过图神经网络去预测空白区域的属性。

2.3 数据集

本实验中选择 Semantic-Kitti 数据集，该数据集包含 28 个类，其中包括区分非运动和运动物体的类。




图 2-6 semantic-Kitti 数据集

同时，本实验采用了 semantic-POSS 数据集，该数据集以北京大学校园为背景，共包含 14 个类别:未标记(0)、人(4,5)、骑手(6)、汽车(7)、树干(8)、植物(9)、交通标志(10,11,12)、电线杆(13)、垃圾桶(14)、建筑(15)、锥形/石头(16)、围栏(17)、自行车(21)、地面(22)。




图 2-7 semantic-POSS 数据集

三、实验结果及分析

1. RangeNet++分割结果

本实验选择 RangeNet++训练好的 darknet53-1024 权重，在 semantic-kitti 的 07 序列上进行测试，并用 semantic-kitti 官方的可视化以及评估函数对结

果进行评估。

本实验使用 IoU 指标对测试结果进行评估，在 07 序列上准确率(acc)为 0.883，mIoU 为 0.457。每一类的 IoU 分别如下所示：

表 2-1 RangeNet++结果


Class	IoU	Class	IoU
1(car)	0.845	11(sidewalk)	0.845
2(bicycle)	0.238	12(other-ground)	0
3(motorcycle)	0.177	13(building)	0.844
4(truck)	0.435	14(fence)	0.506
5(other-vehicle)	0.347	15(vegetation)	0.742
6(person)	0.18	16(trunk)	0.353
7(bicycle)	0.401	17(terrain)	0.803
8(motorcyclist)	0	18(pole)	0.391
9(road)	0.910	19(traffic-sign)	0.470
10(parking)	0.199		

可以看到，RangeNet++对 car、building、road、sidewalk 以及 terrain 等类别上 IoU 均超过 80%，表现较好。所以类别平均 IoU 也达到了 45.7%。表 2-2 给出了 semantic-kitti 官网上现有算法的 mIoU 数据，可以看到，RangeNet++在 semantic-kitti 全部序列上达到了 52.2%。

表 2-2 Semantic-kitti 数据集指标

算法	mIoU
RangeNet++	52.2%
PolarNet	54.3%
JS3C-Net	66.0%

图 3-1 给出了部分数据的可视化结果。



(c)

(d)

图 3-1 RangeNet++分割前后结果对比


2. PolarNet 分割结果

使用 PolarNet 算法对 07 序列进行分割，mIoU 只有 0.148，距离表 2-2 所示的 54.3%存在较大的差距。每一类别的 IoU 结果如表 2-3 所示。


表 2-3 PolarNet 结果

Class	IoU	Class	IoU
1(car)	0.3199	11(sidewalk)	0.2111
2(bicycle)	0.0058	12(other-ground)	0
3(motorcycle)	0.1954	13(building)	0.3438
4(truck)	0.3763	14(fence)	0.1527
5(other-vehicle)	0.0965	15(vegetation)	0.2721
6(person)	0.0234	16(trunk)	0.1053
7(bicycle)	0.0242	17(terrain)	0.0607
8(motorcyclist)	0	18(pole)	0.0878
9(road)	0.4321	19(traffic-sign)	0.0272
10(parking)	0.0753		

图 3-2 展示的 PolarNet 算法分割前后的结果，场景分割效果较差，难以清楚的将各类物体区分出来。



(a)



(b)

图 3-2 PolarNet 分割前后结果对比

3.JS3C 分割结果

JS3C 网络分割的 Acc 为 0.965，mIoU 达到了 0.773，在 07 序列上的效果超过整个数据集的平均水平（表 2-2）。car、motorcycle、sidewalk、building、other-vehicle、bicyclist 几类的 mIoU 超过了 90%。

表 2-4 JS3C 结果

Class	IoU	Class	IoU
1(car)	0.982	11(sidewalk)	0.946
2(bicycle)	0.541	12(other-ground)	0
3(motorcycle)	0.917	13(building)	0.970
4(truck)	0.898	14(fence)	0.775
5(other-vehicle)	0.92	15(vegetation)	0.886
6(person)	0.87	16(trunk)	0.78
7(bicyclist)	0.943	17(terrain)	0.863
8(motorcyclist)	0	18(pole)	0.766
9(road)	0.973	19(traffic-sign)	0.762
10(parking)	0.891		

如图 3-3 所示，可以清楚的从图片右侧看到分割结果，整体分割效果较好。




图 3-3 JS3C 分割前后结果对比

4. JS3C-Net 补全结果

JS3C 网络不仅可以实现语义分割，还可以实现场景补全。同样是以 semantic-kitti 的 07 序列为例进行试验。除了使用 mIoU 作为评价指标外，这里还采取了 completion 评价补全的程度，即将体素只划分为空白/占用，以此来评价补全效果。

补全网络的平均 IoU 为 27.57%，补全程度 completion 为 53.14%。分割的得到的 IoU 达到了 77.3%，而补全后只有 27.57%，可见补全网络还有待进一步提高。

表 2-5 JS3C 补全结果

Class	IoU	Class	IoU
-------	-----	-------	-----

1(car)	0.4168	11(sidewalk)	0.4869
2(bicycle)	0.1164	12(other-ground)	0
3(motorcycle)	0.1723	13(building)	0.4156
4(truck)	0.2634	14(fence)	0.2831
5(other-vehicle)	0.2174	15(vegetation)	0.4047
6(person)	0.1323	16(trunk)	0.1975
7(bicyclist)	0.197	17(terrain)	0.5134
8(motorcyclist)	0	18(pole)	0.2272
9(road)	0.6139	19(traffic-sign)	0.1137
10(parking)	0.4665		

5. Semantic-POSS 数据集结果

本实验还在 semantic-POSS 数据集上进行实验，由于没有 semantic-POSS 的预训练权重，因此首先将数据集 00、01、02、03 划分为训练集，04 为验证集用来训练模型。




图 3-4 训练过程验证集上分割 mIoU、补全 Completion 和补全 mIoU 变化示意图
 由于算力的限制，本实验只训练了 30 个 epoch，验证集上分割的 mIoU 接近 70%，补全的 completion 和 mIoU 在 55%、30%附近。而将该模型分别用来分割和补全，测试集上的分割的 mIoU 为 64.81%，而补全的 completion 和 mIoU 只有 30%和 24.5%。表 2-6 和 2-7 分别为分割和补全任务中每一类别的 IoU 结果。

表 2-6 semantic-POSS 分割结果

Class	IoU	Class	IoU
1(person)	0.7563	11(pole)	0.4752
2(bike)	0.7121	12(rider)	0.6913

3(building)	0.8976	13(traffic-sign)	0.3423
4(car)	0.8993	14(trunk)	0.3231
5(ground)	0.7556	15(fence)	0.6124
6(plants)	0.6655		

表 2-7 semantic-POSS 补全结果

Class	IoU	Class	IoU
1(person)	0.062	11(pole)	0
2(bike)	0.405	12(rider)	0.091
3(building)	0.43	13(traffic-sign)	0.044
4(car)	0.508	14(trunk)	0.15
5(ground)	0.468	15(fence)	0.3955
6(plants)	0.139		

四、实验心得与体会

1.通过本次实验，对激光雷达数据的处理有了更深的认识，能够掌握处理激光雷达点云数据的基本方法；

2.同时也看到，在激光雷达点云数据语义分割、补全这一领域，还有很多的工作需要去完成。目前，激光雷达语义分割最好 SOTA 的 mIoU 也不是很高，而补全的结果更低，还不到 30%，亟需大量的研究；

3.通过《地面无平台自主控制》这一门课，系统的了解了无人车领域环境感知感知、运动控制、决策规划等各个领域，对无人车有了全面的认识与了解，为以后的科研工作打下坚实的基础。